

生成式人工智能对制造企业全要素生产率的影响研究

乔朋华, 赵棒棒, 韩先锋

(昆明理工大学 管理与经济学院, 云南 昆明 650500)

摘要:具备通用目的技术特征的生成式人工智能应用,能够与制造企业经营生产深度融合,促进生产效率提升。以中国制造业上市公司为研究对象,运用 BERT 智能文本分析方法构建生成式人工智能应用衡量指标,系统考察生成式人工智能应用对制造企业全要素生产率的影响及作用机制。研究发现,生成式人工智能应用提升了制造企业全要素生产率;组织内部人力资本升级与组织外部数字基础设施完善对生成式人工智能和企业全要素生产率之间的关系具有正向调节作用。基于资源基础观,从宏观战略层面、中观运营层面、微观要素层面研究发现,生成式人工智能通过提高企业研发配置效率、内部管理效率以及数据要素配置水平促进企业全要素生产率提升。异质性分析表明,生成式人工智能应用成为制造企业全要素生产率转化的共性引擎,相较于西部地区,其对我国中东部地区制造企业全要素生产率促进作用更强;与传统数字技术不同,生成式人工智能在非劳动密集型、非资产密集型和技术密集型企业中的影响更为突出。此外,区域高创新能力将放大技术转化乘数效应,而数字经济发展水平较低区域的技术填补效应更为显著。本研究揭示了生成式人工智能应用影响制造企业全要素生产率的机制,为制造企业深化生成式人工智能与经营生产融合,提升全要素生产率提供实践参考。

关键词:大模型;生成式人工智能;全要素生产率;数智技术;科技创新

DOI:10.6049/kjbydc.D22025090225

开放科学(资源服务)标识码(OSID):



中图分类号:F062.5

文献标识码:A

0 引言

人工智能是推进我国科技跨越发展、产业优化升级、生产力整体跃升的重要战略资源,也是赢得全球科技竞争主动权的强大战略抓手。2025年8月,国务院印发《关于深入实施“人工智能+”行动的意见》,推动以大模型为代表的新一代革命性人工智能技术与各场景深度融合,为经济高质量发展注入新动力。当前,我国人工智能领域的发展势头强劲。国家工业信息安全发展研究中心、工业和信息化部电子知识产权中心发布的《新一代人工智能专利技术分析报告》显示,自2017年以来,中国人工智能专利申请年均增长率超过43%,展现出蓬勃的发展活力。国家数据局发布的《数字中国发展报告(2024年)》显示,全球新公开的4.5万件生成式人工智能专利中,中国新增专利数量达到2.7万件,占比达61.5%。国产大模型 DeepSeek 的强势崛起更加使得“企业级大模型部署”迎来可能,未来人工智能产业发展空间和市场潜力更为广阔。

生成式人工智能(Gen AI; Generative artificial intelligence)作为人工智能领域的技术范式突破,依托预训练模型与大数据驱动实现从数据识别到内容创造的跨越^[1],其核心价值在于通过自主生成文本、图像及决策方案等新型知识产品,重构企业创新链与价值链^[2]。现有研究主要围绕技术赋能路径展开:一方面,证实生成式人工智能通过“云端试错”机制降低研发试错成本^[3],以自动化内容生成替代程序化人力劳动^[4],并通过多模态数据分析优化客户需求洞察与提升供应链响应效率^[5];另一方面,生成式人工智能“人机协同”特性可突破单一主体能力边界,员工通过筛选修正人工智能生成内容实现效率增益^[6-7],进而形成“机器换人”与“人机共生”并存的转型路径。相较于传统数字技术,生成式人工智能的技术溢出效应不仅体现为生产流程局部优化,更通过知识创造机制革新,驱动企业全要素系统性重组^[2],为生产率跃升提供新的可能。

由此引申出当下核心议题:生成式人工智能如何通过影响全要素生产率(TFP)推动企业高质量发展。

收稿日期:2025-09-09 **修回日期:**2026-04-03

基金项目:国家自然科学基金面上项目(72274085);教育部人文社会科学一般规划项目(21YJA630073);云南省基础研究计划重点项目(202401AS070743);云南省哲学社会科学规划“党的二十大精神研究专项”项目(ZX2024YB48)

作者简介:乔朋华(1982—),男,山东单县人,博士,昆明理工大学管理与经济学院教授、博士生导师,研究方向为战略管理;赵棒棒(2001—),男,河北邯郸人,昆明理工大学管理与经济学院硕士研究生,研究方向为战略管理;韩先锋(1984—),男,陕西商洛人,博士,昆明理工大学管理与经济学院教授、硕士生导师,研究方向为创新与产业升级。

企业全要素生产率提升源于技术进步带来的边际产出增加与资源配置优化的双重驱动,其本质体现为等量要素投入下的产出增益,或等量产出下的要素节约^[8]。而智能化发展、“两业融合”等技术创新为全要素生产率提升打开了新通道。已有研究指出,企业全要素生产率通过知识扩散、管理革新与要素组合创新,已成为衡量经济高质量发展与企业生产效率跃迁的综合性标尺^[9-10]。创新驱动的内涵式发展路径,如自主创新通过弱化要素依赖、激发技术溢出效应,成为突破企业全要素生产率增长瓶颈的核心机制^[11-12]。历史经验表明,工业革命引发的技术范式变革通过重构生产要素内涵与催生高附加值产品,系统性推动企业全要素生产率跃升^[13-14]。当前,以人工智能为代表的各类数字技术正通过优化要素配置、重塑生产流程与拓展创新边界,为企业全要素生产率提升注入新动能^[15]。

尽管智能化技术整体上被寄予厚望,但现有研究尚未系统阐释新一代生成式人工智能对企业全要素生产率的影响,其作用机制多停留在技术赋能假说层面。“技术应用—要素重组—效率跃迁”传导路径尚未得到实证检验,“技术优势—生产率跃升”的“黑箱”也尚未打开。制造业作为实体经济的主体,其转型升级是新技术红利释放的“主战场”。因此,本研究将样本明确限定于中国 A 股制造业上市企业,旨在深入探究生成式人工智能在这一关键领域的作用机制。可能的边际贡献如下:第一,运用智能文本分析方法,以 BERT 大模型为基础识别工具,构建微观企业层面生成式人工智能应用衡量指标,为后续相关研究提供有效的度量方法。第二,从研发配置、内部管理与数据要素三个维度识别中介路径,并纳入人力资本升级与数字基础设施两个边界条件,为制造企业在微观层面打通技术红利转换通道提供理论支撑。第三,基于资源基础观,揭示生成式人工智能影响制造企业全要素生产率的机制逻辑,为企业生成式人工智能在行业中的具体应用提供经验证据与借鉴,以期拓展全要素生产率的研究边界。

1 理论基础与研究假设

1.1 生成式人工智能与企业全要素生产率

企业全要素生产率差异,历来被理论界视为解读企业异质性绩效的核心。新古典经济增长理论将其归因于外生技术进步,资源基础观则强调,企业之所以呈现出不同的绩效水平,根本上在于其所拥有的异质性资源及资源组合方式存在差异。此理论脉络下,生成式人工智能对企业全要素生产率的影响,不仅体现为简单的流程自动化或信息处理提速,更在于其能作为重要数字化战略资源嵌入企业生产经营过程,通过优化企业关键资源获取、配置与利用方式,提升资源价值创造能力,进而推动生产率提升。首先,在创新链维

度,生成式人工智能通过重构研发资源配置模式驱动技术前沿外移。区别于传统判别式人工智能,其独特的多模态数据收集、机器学习以及内容生成能力,可将隐性知识转化为显性方案,进而拓展技术搜索广度与深度,并基于产业大模型提升企业效率,本质上体现为企业知识资源基础扩展,以及研发资源利用效率提升。其次,在运营链维度,生成式人工智能通过重塑内部管理资源配置提升技术转化效率。通过自动化、智能化等手段降低生产成本,使原材料采购、研发设计、生产制造、物流运输、终端销售等各链条达到最优运筹,进一步优化企业生产要素配置^[1]。借助生成式人工智能赋能,数字技术进一步交融协同^[15],管理链、创新链、产业链和供应链共同嵌入工业、商业一体化物联网,通过海量数据智能分析和自主调整生产策略,提升产品和市场匹配率,有效解决市场供求的非对称性,进而提升企业生产效率。最后,在要素层维度,生成式人工智能通过提升数据要素配置水平夯实生产率提升的基础。生成式人工智能借助生产智能化特征,对数据进行智能萃取与价值挖掘,提升数据要素的边际产出弹性,解决数据要素配置中的结构性错配问题,降低生产与创新决策过程的出错率和资源损耗,提升企业资源整体利用效率,最大化释放企业发展潜力,进而促进企业生产效率提升。基于此,本文提出以下假设:

H₁:生成式人工智能应用能够提升企业全要素生产率。

1.2 传导机制

生成式人工智能驱动企业全要素生产率提升过程,本质上体现为企业资源基础拓展基础上的关键资源配置效率优化。结合生成式人工智能技术特性,本文进一步从研发资源配置、内部运营资源配置以及数据要素配置三个核心维度,揭示其影响全要素生产率的传导机制。这三个维度分别对应企业价值创造流程中知识创新、运营管理和要素赋能的关键环节,既反映了企业对异质性资源的开发利用,也体现了企业对相关资源的优化配置过程,共同构成生成式人工智能促进全要素生产率增长的微观作用路径。

1.2.1 研发资源配置效率的中介效应

研发活动中企业将有限资本、技术知识与人力资本持续投入具有不确定性的创新,本质是对创新资源进行跨期配置的过程。资源基础观认为,知识、技术、研发人才等创新资源是企业形成异质性竞争优势的重要基础,研发资源配置效率则体现企业对创新资源的开发利用水平。传统创新活动中,企业面临研发资源配置的双重困境:一是创新过程具有高不确定性和高试错成本,有限的人力资本与试错成本约束迫使创新搜索锁定于局部最优区间,难以突破既有技术轨道的路径依赖,导致研发投入难以实现最优配置。二是研发知识具有较强的隐性特征和时空黏性,跨部门、跨主

体协作中存在信息衰减与知识割裂,制约创新资源有效整合,导致知识要素难以跨主体高效流转。

生成式人工智能从三方面突破上述瓶颈:第一,借助多模态数据分析能力系统扫描跨领域技术模块,智能生成超出现有认知的创新组合,使同等研发投入能探索数量倍增的解决方案,大幅提升技术搜索效率^[16];第二,通过虚拟模拟技术替代物理实验,快速验证技术可行性并预判风险,将资源精准导向高潜力方向,减少试错损耗(戚聿东等,2020);第三,构建实时协作平台整合分散的研发经验与用户反馈,将个体知识沉淀为可复用的数字资产,破解知识共享的时空限制^[17]。上述机制能够扩展企业创新资源基础,提高研发资源利用效率,使企业能够以更低成本优化技术路径、缩短创新周期与提升知识复用率,进而通过提升研发资源配置效率推动全要素生产率增长。基于此,本文提出以下假设:

H₂:生成式人工智能应用通过提高研发资源配置效率促进企业全要素生产率提升。

1.2.2 内部管理效率的中介效应

企业内部运营是对人、财、物等运营资源进行持续配置、协调与整合的过程,其管理效率直观反映了内部资源利用与流程协同的优化水平。资源基础观认为,高效的组织管理能力是企业重要的异质性资源,能够通过提升资源使用效率形成持续竞争优势。因此,内部管理效率不仅体现企业既有资源配置质量,也反映企业将技术资源、组织资源和人力资源转化为经营绩效的能力。生成式人工智能所带来的生产要素重新组合与捆绑^[18],将创造性地改变企业内部运作和生产经营过程(徐鹏等,2020),从而提高企业运营效率和盈利水平。一方面,生成式人工智能赋予传统数字技术产品更强的智能性,能够替代人类完成特定工作任务(王军等,2021),有效减少企业对劳动力的重复培训以及企业经营过程中的错误,通过最小化流程偏差保证生产过程和业务流程的一致性,进而提升企业内部管理水平。另一方面,随着数智技术应用水平提高,企业会增加对高素质人才的需求,进而持续优化企业人力资本结构^[19]。而高素质人才能够更有效地理解、吸收并运用生成式人工智能生成的信息与方案,进一步提升企业经营效率。此外,生成式人工智能“智慧大脑”赋能企业解决传统供应链体系中的信息不对称问题,降低交易风险^[20],实现全天候数据信息共享、经营策略智能自主调整以及交易行为智能监督,紧密链接供应链环节各参与方,进而降低信息搜寻成本、合同履行成本和产品开发成本,提高企业运营效率。基于此,本文提出以下假设:

H₃:生成式人工智能应用通过提高内部管理效率促进企业全要素生产率提升。

1.2.3 数据要素配置水平的中介效应

数字经济中,数据已成为企业创造价值与形成竞

争优势的重要战略资源,其价值实现与否取决于数据资源能否在企业内外部高效流动、整合与配置。资源基础观认为,数据作为新型关键资源,其质量、规模与可用性会直接影响企业资源禀赋及其价值创造能力。因此,数据要素配置水平不仅体现企业对数据资源的开发利用程度,也反映企业将数据资源嵌入价值创造过程的效率水平。传统资源配置模式受制于信息获取的时空壁垒与决策滞后性,企业难以实时捕捉市场需求变动、技术演进趋势及供应链动态,导致要素错配与效率损失^[21]。生成式人工智能通过重构数据要素采集、整合与运用范式,为突破资源配置瓶颈提供技术支撑:其一,在数据整合层,生成式人工智能依托深度学习架构对多源异构数据进行非线性建模,将离散的原始数据转化为具有时序关联与业务语义的结构化知识,这种智能化处理机制不仅提升了数据要素的颗粒度与实时性,更通过参数化建模支持市场需求的动态仿真,为企业制定前瞻性资源配置策略提供依据^[22]。其二,在决策支持层,生成式人工智能通过消解信息传递中的噪声干扰与认知偏差,精准识别生产要素组合中的边际效益差异,进而引导企业将数据资源向高价值环节倾斜。这种以数据流驱动资源流的配置模式,能够显著降低传统试错法带来的沉没成本(宋敏等2021)。其三,在价值衍生层,数据要素与生成式人工智能技术形成“使用—优化—增值”的正反馈循环:技术应用提升数据要素的边际产出弹性,而高质量数据池的积累能够持续提升算法预测精度与生成能力,最终通过要素间的协同互补效应突破传统生产率的增长阈值^[23]。这一过程本质上是将低价值的“数据资源”激活为高价值的“数据资产”,提升数据要素在企业决策和创新活动中的配置效率与边际产出。当高质量的数据要素能够更顺畅地配置并赋能研发、生产、营销等价值创造环节时,便驱动生产系统整体效率提升。上述机制表明,生成式人工智能通过拓展企业数据资源基础并提升数据要素配置水平,促进企业全要素生产率增长。基于此,本文提出以下假设:

H₄:生成式人工智能应用通过提升数据要素配置水平促进企业全要素生产率提升。

1.2.4 组织内部人力资本升级的调节效应

生成式人工智能对企业全要素生产率的促进作用不仅取决于技术本身,更依赖于其与企业内部资源基础的协同效应。资源基础观认为,高技能人力资本是企业重要的战略性资源,其数量与质量差异会直接影响企业资源开发利用效率。因此,组织内部人力资本升级不仅体现为高技能劳动者占比提升,也体现为企业知识资源增加和人才资源基础增强^[24]。高技能人才具备更强的抽象思维、批判性评估与技术整合能力,能够更精准地解读生成式人工智能的输出并将其转化为可执行的优化策略,进而减少新技术应用过程中的组织摩擦与协同成本。这意味着高技能人力资本作为关

键互补性资产,通过提升企业在研发、运营及数据管理中对生成式人工智能这一新型资源配置工具的驾驭能力,提升技术应用与资源配置过程中的匹配精度与执行效率。换言之,组织内部人力资本升级能够增强生成式人工智能这一战略资源的使用效果,从而放大其对全要素生产率的促进作用。因此,组织内部人力资本升级实质上强化了生成式人工智能由技术应用向效率提升再到生产率增长的传导机制。基于此,本文提出以下假设:

H₃:组织内部人力资本升级强化了生成式人工智能应用对全要素生产率的影响。

1.2.5 组织外部数字基础设施的调节效应

生成式人工智能对企业全要素生产率的赋能效果,不仅取决于企业内部资源基础,也受到外部数字环境的显著影响。资源基础观认为,企业竞争优势形成不仅依赖内部异质性资源,还受到外部关键支撑资源可得性的约束。因此,区域数字基础设施可被视为企业应用生成式人工智能的重要外部互补性资源,其完善程度将直接影响企业获取、部署并高效利用生成式人工智能的条件。完善的数字基础设施通过大幅降低数据获取、模型训练与交互应用的成本及延迟,为企业提供即时、可靠且可扩展的通用技术基座。这使得企业能够更专注地将内部资源应用于业务场景的深度适配与创新,而非消耗在底层技术瓶颈的突破上,从而显著提升生成式人工智能技术潜能的转化效率。完善的数字基础设施通过提供关键的区域性互补资产,降低企业应用生成式人工智能的交易成本与技术门槛,放大其在创新链、运营链与要素层进行资源配置优化的广度、深度及敏捷性,进而强化生成式人工智能对全要素生产率的促进作用。基于此,本文提出以下假设:

H₄:组织外部数字基础设施完善强化了生成式人工智能应用对全要素生产率的提升作用。

2 数据来源、变量说明与模型构建

2.1 数据来源

当前,聚焦制造业如何克服现实难题,突破高质量发展瓶颈的解决路径,对于“人工智能+”赋能千行百业具有实践指导意义。因此,本文聚焦制造企业,选取2017—2022年中国沪深A股制造行业上市企业为样本进行实证检验。

本文选取巨潮资讯网作为上市公司年报数据来源,企业基本信息和财务数据来自国泰安数据库(CS-MAR)及中国研究数据服务平台(CNRDS)。本文对样本数据进行如下处理:①仅保留制造业行业样本;②剔除当年处于ST和*ST状态样本;③剔除数据缺失样本。最终得到13 716个观测值。为消除极端值影响,本文对连续变量在1%水平上进行缩尾处理。

2.2 变量说明

2.2.1 被解释变量

全要素生产率大幅提升是新质生产力的核心标志^[25],而提高全要素生产率也是企业高质量发展的必然要求,二者高度契合。全要素生产率(TFP)作为企业竞争力的核心表现,常用经典测度方法有OP法^[26]、GMM法以及LP法^[27]。OP法将投资作为代理变量,代理变量(投资)与总产出之间始终保持单调的关系,样本中投资额为零的企业,其全要素生产率无法被估计。GMM法的核心逻辑是通过工具变量解决内生性问题,其有效性高度依赖于工具变量选择和模型设定。LP法将中间投入作为代理变量,能够有效解决因企业投资为零而导致样本损失的问题,在数据利用上更具优势,尤其是在处理企业层面数据时,能够充分利用样本信息,避免因样本筛选偏差而影响估计结果。此外,LP法对数据的要求较低,而制造企业中间投入数据较易获得^[28]。因此,本文使用LP法对企业全要素生产率进行估计。同时为弥补单一方法的不足,采用OP法以及GMM法得到的全要素生产率进行稳健性检验。

2.2.2 解释变量

生成式人工智能应用(GenAI)。在以往人工智能测度研究中,主要有两种方法:一种是以工业机器人单一指标进行衡量^[29];另一种是构建人工智能指标评价体系,综合考察人工智能应用水平。上市公司年报作为反映企业经营战略、技术布局与管理层认知的公开、权威文本,其内容中对特定技术关键词的提及,具有重要的信号意义。因此,本文利用上市公司企业年报中关键词词频所生成的哑变量构建生成式人工智能应用指标。

在构建指标时,文本分析方法的选择也至关重要。传统关键词词频统计法简单直接,但存在明显局限:其一,无法理解词语的上下文语义,容易产生误判;其二,对于“生成式人工智能”这类快速演进、术语体系复杂且高度依赖语境的新兴技术,难以捕捉其语义核心和关联概念。相较于传统方法,采用Transformer架构的BERT预训练语言模型在语义理解方面具有革命性优势,这与生成式人工智能技术特性高度契合。其卓越的语境感知能力、先进的语义相似度计算能力以及与生成式人工智能技术内核的天然适配性能够有效降低指标噪声,避免依赖人工经验选词的主观性和局限性。本文运用BERT智能文本分析方法,基于代表词“大模型”,构建生成式人工智能指标。

(1)生成式人工智能词典。参考乔朋华等(2025)研究,关键词选取见表1。其步骤如下:第一,依据国家工业信息安全发展研究中心《AI大模型发展白皮书》、中国人工智能学会《中国人工智能系列白皮书——大模型技术(2023版)》等,人工选取“生成式人工智能”“大模型”“Transformer架构”等59个词语作

为关键词^[30]。第二,在此基础上运用 BERT 模型,从关键词出发拓展与生成式人工智能相关的词语。第三,剔除重复词语以及与人工智能容易混淆且与生成式人工智能不相关的词语,最终获得 22 个词语,生成生成式人工智能词典。

(2)基于上市公司年报构建生成式人工智能指标。本文采用 Python 环境中开源的“jieba”中文分词工具,对上市公司年报文本进行分词处理。为保证所构建的应用指标有效性,本文通过 BERT 模型再度对生成式人工智能词语进行智能识别,避免出现“AI 幻觉”,进一步采用专家小组审查法,依据公司年报对识别出的关键词进行筛选和核查,剔除类似“较大模型”等混淆词语出现的样本,共计有效样本数据 17 621 份,得到生成式人工智能指标。最终,本文采用上市公司年报中生成式人工智能关键词所生成的哑变量作为其衡量指标,若上市公司采用该技术则赋值为 1,否则为 0。此外,被解释变量采用上市公司年报出现生成式人工智能关键词的哑变量衡量,其无法展现不同公司应用水平差异。因此,本文将上市公司年报出现生成式人工智能关键词的起始年设定为 1,后续逐年加 1,以此构建变量 *GenAI_2* 并用于稳健性检验。

表 1 生成式人工智能关键词选取

Table 1 Key words of generative artificial intelligence

分词维度	分词词典
技术特性与术语类别	生成式人工智能、Generative AI、生成式 AI、AIGC、大模型、Large Model、大语言模型、LLM、预训练模型、Pretrained Model、Transformer 架构、多模态
具体应用技术类别	BERT、GPT、T5、XLNet、BART、Vision Transformer、Sparse Transformers、XLM、U-Net、ELECTRA

2.2.3 中介变量

(1)研发配置效率 (*InnoEff*)。参考权小峰等(2017)的研究,本文使用企业发明专利、实用新型和外观设计专利三种专利的总申请量加 1 的自然对数除以研发支出加 1 的自然对数进行衡量,数值越大代表企业创新效率越高。

(2)内部管理效率 (*Cost*)。企业管理水平提升的重要表现之一是成本费用率大幅降低,借鉴已有研究^[31],本文使用成本费用率体现企业内部管理水平,其计算方法为成本费用率=(主营业务成本+期间费用)/主营业务收入。

(3)数据要素配置水平 (*Indata*)。利用上市公司年报中与数据要素相关的关键词出现频数构造数据要素指标。借鉴政府相关文件、以往文献以及业界报告,本文选取数据要素、大数据、算力、信息、数据化、算法这六个关键词作为与数据要素相关的关键词^[32]。

2.2.4 调节变量

(1)组织内部人力资本升级 (*Techratio*)。人力资本是以劳动者为载体的体力、知识、经验等技能的总

和。参考刘啟仁等^[24]的做法,本文采用技能型员工人数与企业员工总人数的比值表示。

(2)组织外部数字基础设施 (*Digfra*)。借鉴钞小静等^[25]的研究,本文统计 2017—2022 年《政府工作报告》中,与新型数字基础设施相关的词汇数量,并计算新型数字基础设施相关词汇的占比。依据各地级市信息就业人员数量与新型数字基础设施高度相关性的特点,采用地级市信息就业人员数量占总人口的比重对新型数字基础设施的词频比重进行加权处理,即采用二者相乘的结果衡量各地级市新型数字基础设施建设情况。

2.2.5 控制变量

参考既有研究^[33],本文纳入如下控制变量:公司规模 (*Size*)、资产负债率 (*Leverage*)、总资产净利润率 (*Roa*)、营运能力 (*Manage*)、企业年龄 (*Age*)、董事会规模 (*Board*)、独立董事占比 (*Indep*)、两职合一 (*Both*)、资产密集度 (*Cap*)。

本文主要变量定义如表 2 所示。

表 2 主要变量定义

Table 2 Definitions of key variables

变量名称	变量符号	变量测量
企业全要素生产率	<i>TFP</i>	LP 法
生成式人工智能应用	<i>GenAI</i>	具体测度方式见前文
公司规模	<i>Size</i>	员工人数加 1 取自然对数
资产负债率	<i>Leverage</i>	总负债除以总资产
总资产净利润率	<i>Roa</i>	净利润 / 期末总资产
营运能力	<i>Manage</i>	营业周期取对数
企业年龄	<i>Age</i>	上市公司成立年限
董事会规模	<i>Board</i>	董事会人数取对数
独立董事占比	<i>Indep</i>	独立董事除以董事人数
两职合一	<i>Both</i>	董事长和总经理两职合一为 1,否则为 0
资产密集度	<i>Cap</i>	总资产 / 营业收入

2.3 模型设定

为检验生成式人工智能应用对企业全要素生产率的影响,借鉴陶峰等(2017)的研究,本文基于多维固定效应模型,以期更准确地估计变量间的关系。具体而言,该模型能够利用面板数据的结构优势,有效控制不随时间变化的企业异质性以及所有企业在不同时间点面临的共同外部因素,模型设定如下:

$$TFP_{i,t} = \alpha_0 + \alpha_1 GenAI_{i,t} + \sum Control_{i,t} + Ind_{i,t} + Year_{i,t} + \epsilon_{i,t} \quad (1)$$

其中,被解释变量 $TFP_{i,t}$ 为企业 i 在第 t 年的企业全要素生产率;解释变量 $GenAI_{i,t}$ 为企业 i 在第 t 年的生成式人工智能应用程度。在基准回归中,采用上市公司关键词所生成的虚拟变量进行衡量,在替代指标检验中采用上市公司年报关键词累计虚拟变量作为替代指标。根据假设 H_1 ,本文预测回归系数 α_1 显著为正。 $Control_{i,t}$ 为一系列控制变量; $Ind_{i,t}$ 、 $Year_{i,t}$ 分别表示企业和年度固定效应, $\epsilon_{i,t}$ 为随机扰动项。

在机制检验中,参考已有研究^[34],本文采用中介效应模型,通过式(2)~(4)对企业研发配置、内部管理和数据要素三条路径进行检验。

$$TFP_{i,t} = \alpha_0 + \alpha_1 GenAI_{i,t} + \sum Control_{i,t} + Ind_{i,t} + Year_{i,t} + \varepsilon_{i,t} \quad (2)$$

$$M_{i,t} = \alpha_0 + \alpha_1 GenAI_{i,t} + \sum Control_{i,t} + Ind_{i,t} + Year_{i,t} + \varepsilon_{i,t} \quad (3)$$

$$TFP_{i,t} = \alpha_0 + \alpha_1 GenAI_{i,t} + \alpha_2 M_{i,t} + \sum Control_{i,t} + Ind_{i,t} + Year_{i,t} + \varepsilon_{i,t} \quad (4)$$

其中, $M_{i,t}$ 为中介变量,表示企业研发配置效率、内部管理效率和数据要素配置。

3 实证结果分析

3.1 描述性统计

本文主要变量描述性统计结果如表3所示,2017—2022年我国上市公司制造行业企业全要素生产率(TFP)均值为8.277,最大值为11.05;依据上市公司年报中生成式人工智能关键词所生成的虚拟变量,生成式人工智能应用($GenAI$)均值为0.025,方差为0.157,表明现阶段焦点企业在以大模型为主的生成式人工智能技术应用范围较小。

表3 描述性统计结果(N=13 716)

Table 3 Descriptive statistics(N=13 716)

变量	平均值	方差	最小值	最大值
TFP	8.277	0.944	6.295	11.050
$GenAI$	0.025	0.157	0	1
$Size$	7.683	1.147	4.828	11.180
Roa	0.044	0.072	-0.373	0.247
$Manage$	5.300	0.700	3.284	6.899
Age	9.929	7.621	1	32
$Board$	2.091	0.190	1.609	2.708
$Indep$	37.880	5.441	28.570	57.140
$Both$	0.340	0.474	0	1
Cap	2.154	1.454	0.379	15.630
$Leverage$	0.393	0.185	0.008	0.995

3.2 基准回归结果

表4报告了生成式人工智能应用对企业全要素生产率影响的实证结果。列(1)不加入控制变量,回归结果显示,焦点企业生成式人工智能应用($GenAI$)对企业全要素生产率(TFP)的回归系数为0.351,在1%水平上显著。列(2)控制行业固定效应,回归结果显示,焦点企业生成式人工智能应用($GenAI$)对企业全要素生产率(TFP)的回归系数为0.25,在1%水平上显著。列(4)控制年份固定效应,回归结果显示,焦点企业生成式人工智能应用($GenAI$)对企业全要素生产率(TFP)的回归系数为0.229,在1%水平上显著。列(4)同时控制行业和年份固定效应,结果显示,焦点生成式人工智能应用($GenAI$)对企业全要素生产率(TFP)的回归系数为0.225,在1%水平上显著。这表

明,控制变量不变的情况下,焦点企业生成式人工智能应用($GenAI$)每提升1个标准差,其企业全要素生产率(TFP)提升8.9%。这说明生成式人工智能应用显著提升了企业全要素生产率,假设 H_1 成立。

表4 基准回归结果

Table 4 Baseline regression results

变量	TFP			
	(1)	(2)	(3)	(4)
$GenAI$	0.351*** (0.05)	0.250*** (9.22)	0.229*** (8.37)	0.225*** (8.35)
$Size$		0.427*** (90.50)	0.425*** (90.11)	0.431*** (91.89)
$Leverage$		0.818*** (28.19)	0.896*** (31.04)	0.806*** (27.99)
Roa		2.186*** (32.21)	2.152*** (31.14)	2.165*** (32.07)
$Manage$		-0.174*** (-21.50)	-0.192*** (-26.79)	-0.173*** (-21.53)
Age		0.014*** (22.21)	0.015*** (22.75)	0.014*** (21.68)
$Board$		0.171*** (5.94)	0.206*** (7.01)	0.185*** (6.48)
$Indep$		0.004*** (4.23)	0.005*** (4.88)	0.004*** (4.35)
$Both$		-0.027*** (-2.90)	-0.033*** (-3.49)	-0.032*** (-3.44)
Cap		-0.126*** (-35.76)	-0.126*** (-35.18)	-0.125*** (-35.83)
$Year$	YES	NO	YES	YES
Ind	YES	YES	NO	YES
常数项	8.268*** (0.01)	5.120*** (52.48)	5.104*** (52.81)	5.062*** (52.25)
样本数	13 716	13 716	13 716	13 716
Adj- R^2	0.121	0.734	0.717	0.739

注:***、**、* 分别表示在10%、5%、1%水平上显著;括号内为t统计值,下同

3.3 稳健性检验

3.3.1 更换变量测度方式

企业全要素生产率存在多种测量方式,本文使用OP法以及GMM法所得到的企业全要素生产率进行稳健性检验。此外,仅采用生成式人工智能应用的虚拟变量指标,难以解释不同应用年限导致应用水平差异所带来的复杂问题,故本文采用累计虚拟变量 $GenAI_2$ 作为解释变量指标进行稳健性检验,结果如表5所示。列(1)(2)回归结果显示,生成式人工智能应用对企业全要素生产率具有显著正向影响。同时,列(3)中 $GenAI_2$ 系数为0.073且在1%水平上显著,说明本文结果稳健。

3.3.2 更换样本期间

为捕捉生成式人工智能对全要素生产率的净效应,排除早期技术不成熟和外部冲击影响,本文将样本区间调整为2020—2022年进行稳健性检验。表6列(1)为更换样本区间的检验结果。同时,控制年份和行

业固定效应实证检验发现,生成式人工智能应用(*GenAI*)的系数为0.202且在1%水平上显著。上述结果与前文结果基本一致,表明本文结果稳健。

表5 稳健性检验结果(1)

Table 5 Robustness test results(1)

变量	TFP_OP (1)	TFP_GMM (2)	TFP (3)
<i>GenAI_2</i>			0.073 *** (8.09)
<i>GenAI</i>	0.198 *** (7.29)	0.224 *** (8.43)	
Controls	YES	YES	YES
Year	YES	YES	YES
Ind	YES	YES	YES
常数项	5.393 *** (55.22)	4.928 *** (51.49)	5.062 *** (52.24)
样本数	13 716	13 716	13 716
Adj-R ²	0.589	0.528	0.739

3.3.3 被解释变量滞后一期

考虑到生成式人工智能应用与企业全要素生产率间可能存在的互为因果关系会引发内生性问题,本文采用滞后一期的企业全要素生产率作为被解释变量,检验生成式人工智能应用对制造企业全要素生产率的影响。表6列(2)回归结果显示,生成式人工智能应用(*GenAI*)的系数为0.265且在1%水平上显著。

表6 稳健性检验结果(2)

Table 6 Robustness test results(2)

变量	更换样本区间 (1)	滞后一期 (2)
<i>GenAI</i>	0.202 *** (6.35)	0.265 *** (7.14)
Controls	YES	YES
Year	YES	YES
Ind	YES	YES
常数项	4.899 *** (37.77)	4.798 *** (40.68)
样本数	7 725	10 521
Adj-R ²	0.748	0.713

3.4 内生性问题处理

3.4.1 倾向得分匹配(PSM)

生成式人工智能技术应用可能并非随机,而是受到行业特性、企业管理者行为、外部政策冲击等因素的影响,这种选择过程可能导致自选择偏误问题。本文采用倾向得分匹配(PSM)方法寻找与处理组相邻的对照组以缓解内生性问题。参考范合军等(2023)的研究,选择本文控制变量作为匹配变量,以Logit模型进行倾向评分,采用1:3最近邻匹配法进行样本匹配,匹配后对获得的有效观测值重新回归。表7列(1)为PSM检验结果,生成式人工智能应用(*GenAI*)的系数为0.191且在1%水平上显著,表明本文研究结果稳健。

3.4.2 工具变量法(IV)

本文通过构造工具变量缓解内生性问题。在工具

变量选取方面,参考李唐等(2020)、杨金玉等(2022)的研究,采用生成式人工智能应用(*GenAI*)与按行业二级编码和省份分类的生成式人工智能应用指标均值差额的三次方作为工具变量。该方法不仅考虑了企业生成式人工智能应用水平,还结合行业和地区平均水平,通过捕捉企业在该领域的相对位置,确保工具变量与潜在内生性解释变量间具有较强的相关性。同时,其他行业和地区的增加值和均值变化难以影响当前企业发展水平,且该指标不直接反映企业的特定行为或决策,满足排他性要求。回归结果如表7列(2)(3)所示,经检验第一阶段F统计量大于10,表明先选取的工具变量不存在弱工具变量问题。列(2)为第一阶段工具变量IV对自变量生成式人工智能应用(*GenAI*)的影响,系数为0.257且在1%水平上显著。列(3)为第二阶段的回归结果,生成式人工智能应用(*GenAI*)的回归系数为0.191且在1%水平上显著,验证了生成式人工智能应用能够促进企业高质量发展。综上,本文研究结果稳健。

表7 内生性检验结果

Table 7 Endogeneity test results

变量	PSM 匹配 (1)	2SLS_1 (2)	2SLS_2 (3)
<i>GenAI</i>	0.191 *** (4.62)		0.191 *** (6.88)
IV		0.257 *** (6.86)	
Controls	YES	YES	YES
Year	YES	YES	YES
Ind	YES	YES	YES
常数项	5.991 *** (40.07)	5.061 *** (52.20)	5.103 *** (50.73)
样本数	7 192	13 716	13 716
Adj-R ²	0.460	0.738	0.739

3.5 机制分析

3.5.1 研发配置效率

表8列(1)中,生成式人工智能应用(*GenAI*)的系数为0.014且在1%水平下显著,表明生成式人工智能应用提高了企业技术创新水平;表8列(2)中,生成式人工智能应用(*GenAI*)与研发配置效率(*InnoEff*)的系数在1%水平下显著,表明企业研发配置效率提升对全要素生产率具有促进作用。上述结果表明,生成式人工智能应用通过提升企业研发资源配置效率提升企业全要素生产率,假设H₂成立。

3.5.2 内部管理效率

表8列(3)中,生成式人工智能应用(*GenAI*)系数为-0.046且在1%水平上显著,说明生成式人工智能应用显著降低了企业成本费用率;表8列(4)中,生成式人工智能应用(*GenAI*)与内部管理效率(*Cost*)在1%水平上对企业全要素生产率均具有显著影响。这说明生成式人工智能应用使得原有要素通过重新链接达到更优组合,提高了企业内部管理控制能力,促进了

全要素生产率提升,假设 H_3 成立。

3.5.3 数据要素配置水平

表 8 列(5)中,生成式人工智能应用 (*GenAI*) 系数为 0.263 且在 1%水平上显著,说明生成式人工智能应用显著提升了数据要素配置水平;表 8 列(6)中,生成

式人工智能应用 (*GenAI*) 与数据要素配置水平 (*Indata*) 在 1%水平上对企业全要素生产率均具有显著影响。这说明生成式人工智能应用通过要素配置提升企业数据要素配置水平,促进全要素生产率提升,假设 H_4 成立。

表 8 中介效应分析结果
Table 8 Test results of the mediating effect

变量	<i>InnoEff</i> (1)	<i>TFP</i> (2)	<i>Cost</i> (3)	<i>TFP</i> (4)	<i>Indata</i> (5)	<i>TFP</i> (6)
<i>GenAI</i>	0.014 *** (4.24)	0.213 *** (7.93)	-0.046 *** (-6.44)	0.222 *** (8.26)	0.263 *** (15.94)	0.177 *** (6.54)
<i>InnoEff</i>		0.893 *** (12.74)				
<i>Cost</i>				-0.140 *** (-4.26)		
<i>Indata</i>						0.184 *** (13.24)
Controls	YES	YES	YES	YES	YES	YES
Year	YES	YES	YES	YES	YES	YES
Ind	YES	YES	YES	YES	YES	YES
常数项	-0.093 *** (7.91)	5.145 *** (53.29)	1.278 *** (50.20)	5.248 *** (49.67)	3.807 *** (64.12)	4.363 *** (39.73)
样本数	13 716	13 716	13 716	13 716	13 716	13 716
Adj-R ²	0.356	0.742	0.548	0.742	0.221	0.742

3.6 调节效应

组织内部企业人力资本升级和组织外部数字基础设施的调节作用检验结果见表 9。表 9 列(1)表明,生成式人工智能应用 (*GenAI*) 与组织内部人力资本升级 (*Techratio*) 乘积项的回归系数显著为正,表明企业内部高技能人力资源越丰富,生成式人工智能应用对企业全要素生产率的影响越显著,假设 H_5 成立。原因在于,高技能人力资本与生成式人工智能技术之间存在显著的能力互补效应,高技能人才更善于理解和驾驭生成式人工智能的输出,并将其转化为更优决策与创新行动,从而放大技术在优化资源配置方面的效能。列(2)表明,生成式人工智能应用 (*GenAI*) 与组织外部数字基础设施 (*Digfra*) 乘积项的回归系数显著为正,组织外部数字基础设施强化了生成式人工智能对企业全要素生产率的影响,假设 H_6 成立。原因在于,高质量网络、算力等基础服务显著降低了模型部署、数据流转与交互应用门槛及成本,使其生成的知识与方案能更顺畅、更低耗地融入企业价值链,从而放大其在优化资源配置上的规模效应与敏捷性。

3.7 异质性分析

3.7.1 产权性质

生成式人工智能通过技术赋能、要素重构与组织变革三大核心机制,成为提升企业全要素生产率的引擎。国有企业在政策支持与规模场景中聚焦重大创新和战略目标实现,非国有企业则在市场机制下追求效率与成本优势,最终形成“差异化路径,同向生产率提升”的格局。为了检验上述推断,本文将样本企业按照

股权性质划分为国有企业和非国有企业,并进行分组回归检验,结果如表 10 列(1)(2)所示。国有企业中,生成式人工智能应用 (*GenAI*) 系数为 0.322 且在 1%水平上显著;非国有企业中,生成式人工智能应用 (*GenAI*) 系数为 0.189 且在 1%水平上显著,验证了上述推断。

表 9 调节作用检验结果
Table 9 Test results of the moderating roles

变量	组织内部 人力资本 (1)	组织外部 数字基础设施 (2)
<i>GenAI</i> × <i>Techratio</i>	0.661 *** (-9.72)	
<i>GenAI</i> × <i>Digfra</i>		0.845 *** (-7.71)
Controls	YES	YES
Year	YES	YES
Ind	YES	YES
常数项	5.055 *** (-52.22)	5.090 *** (-52.43)
样本量	13 716	13 716
Adj-R ²	0.739	0.739

3.7.2 地区特性

区域间要素禀赋的非对称分布构成技术扩散的底层约束,东部、中部地区依托成熟的产业互补与阶梯生态,具备高阶要素集聚优势,更易实现生成式人工智能技术深度渗透与生产率转化;制度环境的梯度差异塑造技术应用的边际成本,各地区受限于市场化滞后与创新网络断层,可能面临技术适配性衰减与协同效应耗散。总之,经济发展基础、产业结构、技术准备度、要

素禀赋以及政策环境等多方面因素的综合作用,促使东部地区在生成式人工智能应用和效益转化上表现更为显著;中部地区凭借承接产业转移和劳动力优势,也能较快显现生成式人工智能应用效果;西部地区受制于产业结构、技术基础和创新生态等因素,技术影响显现相对滞后。此外,本文作数据清洗后,东北地区样本量较小,故未纳入分组作分析。表 10 列(3)~(5)显示,在东部和中部地区,生成式人工智能应用对企业全要素生产率均发挥促进作用,其系数分别为 0.257 和 0.331,均在 1%水平上显著,而西部地区则不显著。这验证了生成式人工智能技术扩散过程中地理空间与经济发展程度的耦合作用。

表 10 异质性分析结果(1)
Table 10 Heterogeneity analysis results(1)

变量	国有企业 (1)	非国有企业 (2)	东部地区 (3)	中部地区 (4)	西部地区 (5)
GenAI	0.322 *** (5.01)	0.189 *** (6.18)	0.257 *** (8.81)	0.331 *** (2.94)	-0.072 (-0.92)
Controls	YES	YES	YES	YES	YES
Year	YES	YES	YES	YES	YES
Ind	YES	YES	YES	YES	YES
常数项	4.748 *** (25.12)	5.759 *** (48.35)	5.422 *** (46.26)	3.448 *** (13.00)	4.770 *** (21.51)
样本数	3 210	10 145	9 924	1 629	2 149
Adj-R ²	0.775	0.706	0.734	0.795	0.782

3.7.3 要素投入

生成式人工智能对企业全要素生产率的影响,会因企业要素禀赋结构差异而呈现显著异质性。资源基础观认为,不同企业在劳动、技术与资本等关键资源上的禀赋差异,会影响其对新技术的吸收能力与价值转化效率。本文参考既有文献,运用 SPSS Statistics22 软件对基年(2017 年)样本公司进行聚类分析^[35]。根据要素密集度将样本划分为劳动密集型企业、技术密集型

企业和资本密集型企业。

从劳动要素投入看,劳动密集型行业则主要依赖人力资源,生成式人工智能应用可能会带来劳动力市场的结构性变化。既有研究指出,数字技术应用对劳动密集型企业具有更为显著的影响^[31]。表 11 列(1)(2)表明,与传统数字技术主要提升劳动密集型企业局部效率不同,生成式人工智能凭借数据生成与多场景适配能力,在非劳动密集型企业中影响更为显著。其技术特性突破了传统技术仅优化单一生产环节的局限,通过全链条渗透实现系统性增效。

从技术要素投入看,技术密集型行业的高研发密度特征与生成式人工智能存在技术迭代的天然适配性;其前沿技术生态能有效承接生成式人工智能的数据解析与知识重组优势,将信息资源势能转化为全要素生产率增益。相较于传统行业,技术密集型领域通过生成式人工智能强化了行业知识网络的协同创新效应,在加速技术扩散的同时实现创新效能的多级放大,这本质上源于生成式人工智能对技术研发“试错—迭代”范式的革命性改写。表 11 列(3)(4)中,生成式人工智能应用 (GenAI) 在技术密集型企业中的系数为 0.247 且在 1%水平上显著,说明生成式人工智能技术作为“创造知识的知识”,对技术创新能力的赋能效应显著。

从资本要素投入看,资产密集型行业的刚性特征显著制约生成式人工智能的技术效能转化。此类行业存在双重锁定效应:其一,重资产运营模式形成高度路径依赖,生产范式的物理惯性与安全冗余阈值共同构成技术替代壁垒;其二,专用性固定资产占比过高导致技术嵌入摩擦系数显著提升,生成式人工智能的柔性创新优势难以突破设备迭代周期与工艺稳定性的约束边界。表 11 列(5)印证了前述推测。

表 11 异质性分析结果(2)
Table 11 Heterogeneity analysis results(2)

变量	劳动密集型 (1)	非劳动密集型 (2)	技术密集型 (3)	非技术密集型 (4)	资产密集型 (5)	非资产密集型 (6)
GenAI	0.130 * (1.71)	0.241 *** (8.42)	0.247 *** (8.36)	0.113 * (1.69)	0.051 (0.31)	0.230 *** (8.29)
Controls	YES	YES	YES	YES	YES	YES
Year	YES	YES	YES	YES	YES	YES
Ind	YES	YES	YES	YES	YES	YES
常数项	5.131 *** (23.37)	5.020 *** (46.23)	4.946 *** (38.47)	5.219 *** (35.06)	5.451 *** (26.91)	5.040 *** (45.76)
样本数	2 805	10 911	8 404	5 312	2 507	11 209
Adj-R ²	0.730	0.742	0.728	0.753	0.788	0.727

上述异质性检验显示,与传统自动化技术主要替代程序化劳动不同,生成式人工智能对企业全要素生产率的促进作用在非资产密集型、非劳动密集型和技术密集型企业中更为显著,这一差异根植于生成式人工智能的技术本质。传统自动化技术旨在优化既定流程、替代重复性体力或脑力劳动,故在劳动密集型企业

中效果显著。而生成式人工智能的核心优势在于其内容生成、逻辑推理与复杂问题解决能力,更像一个知识增强工具,而非简单的劳动替代工具。在技术密集型企业,员工具备较高的专业知识和技能,能更有效地优化人工智能生成方案,进而将生成式人工智能的潜力转化为高质量创新产出。在劳动密集型企业,工作流

程相对标准化,生成式人工智能的创造性潜能难以充分发挥。此外,技术密集型企业通常具备更优质的数字化基础和高质量数据资源,为生成式人工智能应用提供基础资源。因此,生成式人工智能的影响呈现出显著的技能偏向性或知识偏向性,其红利更青睐于人力资源基础和数字基础设施更完善的企业,本文的调节效应检验结果也印证了这一结论。

3.7.4 数字经济发展水平

数字经济生态系统多维度影响生成式人工智能的技术渗透深度与创新协同效能,而我国区域间数字化进程的梯度差异可能构成技术红利释放的制度性约束或加速器。参考王军等^[36]构建的中国省际数字经济发展水平指标体系,使用客观赋权法中的熵值法对指标进行赋权,并对不同层次且量纲与数量级均存在显著差异的 30 个指标进行标准化处理,处理正向和负向指标的公式如下:

$$\text{正向指标: } x_{ij} = \frac{x_{ij} - \min\{x_j\}}{\max\{x_j\} - \min\{x_j\}} \quad (5)$$

$$\text{负向指标: } x_{ij} = \frac{\max\{x_j\} - x_{ij}}{\max\{x_j\} - \min\{x_j\}} \quad (6)$$

其中, $\max\{x_j\}$ 为所有年份中指标的最大值, $\min\{x_j\}$ 为所有年份中指标的最小值, x_{ij} 为无量纲化结果。对指标标准化处理后,按照熵值法步骤得到各指标客观权重,计算第 i 年 j 项指标所占比重,使用 ω_{ij} 表示:

$$\omega_{ij} = \frac{x_{ij}}{\sum_{i=1}^m x_{ij}} \quad (7)$$

计算指标的信息熵 e_j , 则:

$$e_j = -\frac{1}{\ln m} \sum_{i=1}^m \omega_{ij} \times \ln \omega_{ij} \quad (8)$$

计算信息熵冗余度 d_j :

$$d_j = 1 - e_j \quad (9)$$

其中, m 为评价年度,根据信息熵冗余度计算指标权重 φ_j :

$$\varphi_j = \frac{d_j}{\sum_{j=1}^m d_j} \quad (10)$$

基于标准化的指标 x_{ij} 与测算的指标权重 φ_j , 使用多重线性函数的加权求出数字经济发展水平的指数水平(DED CI_i)。计算公式如下:

$$DEDCI_i = \sum_{j=1}^m \varphi_j \times \omega_{ij} \quad (11)$$

通过上述公式计算的数字经济发展综合指数展现了不同区域数字经济发展水平,其中, $DEDCI_i$ 表示 i 省数字经济发展综合指数,介于 0~1 之间。 $DEDCI_i$ 越大,则表示数字经济发展水平越高,反之亦然。

根据 $DEDCI_i$ 中位数,将高于中位数的地区视为数字经济发展水平较高地区,其余则为数字经济发展水平较低地区。设置数字经济发展水平虚拟变量,将

高数字经济发展水平地区赋值为 1,反之赋值为 0。表 12 列(1)(2)显示,生成式人工智能应用在数字经济发展水平较低地区,生产效率转化效果更为显著。这可能源于两类机制:其一,低水平区域传统数字技术沉淀薄弱,生成式人工智能通过填补数字化缺口产生“替代式增长红利”,其边际产出高于已形成技术路径依赖的高水平地区。其二,数字经济发展水平较低地区通过基建跃迁(如直接部署本地化大模型)实现“技术蛙跳”,而高水平地区受既有系统兼容性约束,易陷入“结构性刚性陷阱”。这与后发优势理论形成呼应,印证了技术扩散存在非线性阈值效应:在区域数字化基础跨越特定临界值后,生成式人工智能的增量贡献将让位于协同创新成本。

3.7.5 区域创新能力

区域创新能力分层可揭示生成式人工智能的技术扩散是否存在“吸收能力阈值”。高创新能力区域的协同创新网络能有效放大生成式人工智能对全要素生产率的乘数效应,低创新能力区域的要素错配则会弱化技术转化效能。本文参考中国科技发展战略研究小组联合中国科学院大学中国创新创业管理研究中心编写的《中国区域创新能力评价报告》,将区域创新能力指数作为区域创新能力的代理变量。该指数通过建立四级指标体系(一级指标 5 个、二级指标 20 个、三级指标 40 个、基础指标 138 个),反映各地区创新综合能力方面的表现。本文根据变量中位数,设置区域创新能力虚拟变量,将高创新能力地区赋值为 1,反之赋值为 0。异质性分析结果如表 12 列(3)(4)所示。

表 12 异质性分析结果(3)

Table 12 Heterogeneity analysis results(3)

变量	数字经济发展	数字经济发展	区域创新	区域创新
	水平高	水平低	能力高	能力低
	(1)	(2)	(3)	(4)
GenAI	0.130 *	0.241 ***	0.247 ***	0.113 *
	(1.71)	(8.42)	(8.36)	(1.69)
Controls	YES	YES	YES	YES
Year	YES	YES	YES	YES
Ind	YES	YES	YES	YES
常数项	5.299 ***	3.797 ***	5.240 ***	4.155 ***
	(50.72)	(14.5)	(49.58)	(17.19)
样本数	11 957	1 758	11 706	2 008
Adj-R ²	0.733	0.788	0.730	0.797

4 结语

4.1 研究结论

生成式人工智能应用已成为重塑企业生产管理结构、提升企业竞争力的关键路径。生成式人工智能应用是制造企业将人工智能技术嵌入研发、管理与数据利用等关键环节的重要战略资源,其对制造企业全要素生产率的促进作用,本质上体现为企业资源基础扩展、关键资源配置优化以及资源价值释放能力提升的

综合结果。本文以 2017—2022 年中国制造业 A 股上市公司为样本,运用 BERT 智能文本分析方法构建生成式人工智能应用衡量指标,系统考察生成式人工智能应用对制造企业全要素生产率的影响及作用机制。基准回归发现,生成式人工智能应用提升了制造企业全要素生产率;调节效应分析发现,企业内部人力资本升级与外部数字基础设施完善对生成式人工智能和企业全要素生产率之间的关系具有正向调节作用。机制分析发现,基于战略性资源、运营性资源、生产要素资源三个资源配置层面,生成式人工智能通过优化研发配置、内部管理及数据要素水平提升制造企业全要素生产率;异质性分析发现,不同产权性质企业应用生成式人工智能均能显著提升生产效率,但其效能的发挥高度依赖企业与区域的情境特征。这表明,生成式人工智能应用对企业全要素生产率的促进作用并非简单源于引入技术,而在于其能够与企业内部知识资源、组织资源和数据资源形成有效耦合。此外,生成式人工智能应用对企业全要素生产率的提升作用具有显著的条件性和结构性特征,企业能否享受技术红利,取决于其资源基础能否支撑技术吸收、场景嵌入与价值转化。企业微观层面,其效能的发挥在非劳动密集型、非资产密集型和劳动密集型企业中更为突出,在资产密集型和劳动密集型企业中相对有限。这反映了生成式人工智能作为知识赋能型技术与柔性生产结构和创新活动的协同效应,其效能的发挥受到企业人力资本结构、创新强度等因素影响。区域宏观层面,东部和中部地区的显著效应印证了成熟经济生态的支撑作用,而西部地区效应的不显著性则警示了技术扩散可能存在滞后效应。在高创新能力区域,生成式人工智能应用对制造企业全要素生产率的影响更为显著。此外,数字经济发展水平较低地区显现出“填补效应”,这为后发地区实现“技术蛙跳”提供了实践指导与理论启示。

本文为制造企业后续推进“人工智能+”促进全要素生产率提升的影响效应及作用机制提供了实证支持,验证了生成式人工智能应用能够提升制造企业全要素生产率,并揭示了其内在作用机制与现实边界。总体来说,生成式人工智能并非普遍适用、自动生效的“万能技术”,而是只有在适宜资源基础和环境条件下才能充分释放效能的战略性资源。这一结论为理解生成式人工智能如何赋能实体经济、推动制造业转型升级和培育新质生产力提供了更具解释力的经验证据与理论启示。

4.2 研究启示

对于制造企业而言,需加速推动生成式人工智能的实际应用,将其作为提升企业资源配置效率和强化资源基础的重要抓手。聚焦研发、内部管理与数据要素三大关键节点,打通生产力跃迁通道。具体而言,构建私有化、一体化大模型平台,基于领域知识进行高效

微调,打造专属企业“大脑”,发挥其在研发环节的创新资源整合与方案优化作用,并将其融入内部流程管理全链条。此外,构建企业级知识库,盘活数据要素资源,实现从“被动应对”到“主动预测”和“智能调整”的转变。对于不同制造业行业而言,需结合自身资源禀赋与生产特征,推动生成式人工智能深入各类业务场景,融入行业生产系统,落地核心场景应用,逐步形成产业大模型。优化人力资本结构,进一步推动人机协同,提高技术人员知识创造水平。积极构建行业协同生态,鼓励龙头企业搭建开放平台,推动生成式人工智能在研发设计、生产调度等核心环节的成功经验沿产业链纵向渗透,通过数据要素跨企业流动与优化配置,实现技术红利全行业普惠共享。

对于政府而言,需精准实施差异化政策以构建良好生态。聚焦弥补数字鸿沟、强化要素支撑与完善治理框架,关注区域发展差异,通过加强数字基础设施建设,构建算力网络、数据中心,提供专项政策扶持,推动算力资源西迁,降低欠发达地区企业应用生成式人工智能的门槛。同时,行业规划需根据不同地区、不同类型的现实基础,支持东部创新区域聚焦前沿突破,推动中西部地区立足产业特色承接技术转化,构建全国协同发展的智能制造体系,实现技术红利全域共享。此外,需强化算力、数据、算法等关键要素支撑体系,充分发挥高创新能力区域的“乘数效应”与低数字经济发展水平地区的“填补效应”,为生成式人工智能广泛落地与效能释放提供制度保障。

4.3 不足展望

本文存在以下不足:首先,本研究借助 Python 及智能文本识别技术构建生成式人工智能应用指标,并验证了技术红利释放的路径可行性,但基于关键词生成的哑变量以及在稳健性检验中采用的应用水平衡量指标,难以全面展现出不同应用程度所带来的生产率提升幅度差异,未来可尝试建立更加完善的效用指标作进一步分析。其次,研究样本上,可进一步探究生成式人工智能应用对金融业、教育业等不同行业企业的影响。此外,生成式人工智能应用对企业开放式创新、供应链韧性以及产业链协同效率等是否具有显著影响,也值得深入探讨。最后,本文样本期设定为 2017—2022 年,主要基于多源数据匹配后的完整性、稳定性与可比性考虑,未来可考虑更新样本,以检验本文结论在生成式人工智能加速普及阶段的适用性。

参考文献:

- [1] O'MEARA S. AI researchers in China want to keep the global-sharing culture alive[J]. Nature, 2019, 569(7758): 33-35.
- [2] WANG W G,GAO G D,AGARWAL R. Friend or foe? teaming between artificial intelligence and workers with varia-

- tion in experience[J]. *Management Science*, 2023, 70(9): 5753-5775.
- [3] AGRAWAL A, GANS J, GOLDFARB A. The economics of artificial intelligence[M]. Chicago: University of Chicago Press, 2019.
- [4] 毛日昇. 工业机器人应用与就业再配置[J]. *管理世界*, 2024, 40(9): 98-116.
- [5] FÜGENER A, GRAHL J, GUPTA A, et al. Will humans-in-the-loop become Borgs? merits and pitfalls of working with AI[J]. *MIS Quarterly*, 2021, 45(3): 1527-1556.
- [6] CAO S A, JIANG W, WANG J B, et al. From man vs. machine to man + machine: the art and AI of stock analyses[J]. *Journal of Financial Economics*, 2024, 160: 103910.
- [7] FÜGENER A, GRAHL J, GUPTA A, et al. Cognitive challenges in human-artificial intelligence collaboration: investigating the path toward productive delegation[J]. *Information Systems Research*, 2021, 33(2): 678-696.
- [8] 周宏伟, 鹿素勤, 刘曙光, 等. 数字化投入、本土市场规模与全要素生产率增长[J]. *当代财经*, 2025, 40(9): 126-139.
- [9] 刘潘, 张子尧. 地方公共债务与资源配置效率: 企业间全要素生产率分布差异的视角[J]. *经济研究*, 2023, 58(10): 114-133.
- [10] 陈肖雄, 黄晓迪, 刘贯春, 等. 税收征管数字化的溢出效应研究——基于银行信贷配置效率改善的视角[J]. *中国农村经济*, 2025, 41(2): 153-174.
- [11] 王永中, 刘东升. 机器人应用与全要素生产率——来自全球生产率分化的经验证据[J]. *经济与管理研究*, 2025, 46(2): 3-23.
- [12] 李海舰, 李真真. 数字化转型对企业高质量发展和高速增长的影响——基于“质量变革、效率变革、动力变革”视角的检验[J]. *中国农村经济*, 2024, 40(4): 120-140.
- [13] 黄群慧. 论新时期中国实体经济的发展[J]. *中国工业经济*, 2017, 34(9): 5-24.
- [14] 海本禄, 马昂. 企业创新如何影响全要素生产率——创新广度与创新深度视角[J]. *科技进步与对策*, 2025, 42(4): 78-89.
- [15] 曹玉平, 侯迎信. 智能制造计划可以跨越“生产率悖论”吗: 来自智能制造试点示范项目的准自然实验[J]. *中国软科学*, 2024, 39(6): 23-32.
- [16] BABINA T, FEDYK A, HE A, et al. Artificial intelligence, firm growth, and product innovation[J]. *Journal of Financial Economics*, 2024, 151: 103745.
- [17] 蔡文著, 汤莎. 技术冲击意识对员工知识共享行为的双刃剑效应[J]. *科技进步与对策*, 2026, 43(3): 149-160.
- [18] WILLIAMSON O E. The economics of organization: the transaction cost approach[J]. *American Journal of Sociology*, 1981, 87(3): 548-577.
- [19] 于宝君, 宫婷婷, 朱慧敏, 等. 数智技术应用与制造企业服务化转型——创新资源配置及双元创新能力的链式中介作用[J]. *科技进步与对策*, 2025, 42(8): 57-68.
- [20] 李长英, 王曼. 供应链数字化能否提高企业全要素生产率? [J]. *财经问题研究*, 2024, 46(5): 75-88.
- [21] 周明生, 赵彬彬, 张婷婷. 数字经济、要素错配与产业结构升级[J]. *统计与决策*, 2024, 40(20): 113-118.
- [22] 程兵. 以 ChatGPT 为代表的大语言模型打开了经济学和其他社会科学研究范式的巨大新空间[J]. *计量经济学报*, 2023, 3(3): 589-614.
- [23] 杨慧梅, 江璐. 数字经济、空间效应与全要素生产率[J]. *统计研究*, 2021, 38(4): 3-15.
- [24] 刘啟仁, 赵灿. 税收政策激励与企业人力资本升级[J]. *经济研究*, 2020, 55(4): 70-85.
- [25] 钞小静, 廉园梅, 罗鑒鎔. 新型数字基础设施对制造业高质量发展发展的影响[J]. *财贸研究*, 2021, 32(10): 1-13.
- [26] OLLEY G S, PAKES A. The dynamics of productivity in the telecommunications equipment industry[J]. *Econometrica*, 1996, 64(6): 1263-1297.
- [27] LEVINSOHN J, PETRIN A. Estimating production functions using inputs to control for unobservables[J]. *Review of Economic Studies*, 2003, 70(2): 317-341.
- [28] 鲁晓东, 连玉君. 中国工业企业全要素生产率估计: 1999—2007[J]. *经济学(季刊)*, 2012, 12(1): 541-558.
- [29] 陈东, 秦子洋. 人工智能与包容性增长——来自全球工业机器人使用的证据[J]. *经济研究*, 2022, 57(4): 85-102.
- [30] 乔朋华, 杜鑫, 韩先锋. 生成式人工智能如何提升制造业企业韧性? [J/OL]. *科学学与科学技术管理*, 1-22[2025-08-27]. <https://doi.org/10.20201/j.cnki.ssstm.20250827.001>.
- [31] 赵宸宇, 王文春, 李雪松. 数字化转型如何影响企业全要素生产率[J]. *财贸经济*, 2021, 42(7): 114-129.
- [32] 赵丽, 胡植尧. 数据要素、动态能力与企业全要素生产率——破解“数据生产率悖论”之谜[J]. *经济管理*, 2024, 46(7): 55-72.
- [33] 叶康涛, 孙苇杭. 会计软件采用与企业生产率——来自非上市公司的证据[J]. *会计研究*, 2019, 40(1): 45-52.
- [34] 温忠麟, 叶宝娟. 中介效应分析: 方法和模型发展[J]. *心理科学进展*, 2014, 22(5): 731-745.
- [35] 肖曙光, 杨洁. 高管股权激励促进企业升级了吗——来自中国上市公司的经验证据[J]. *南开管理评论*, 2018, 21(3): 66-75.
- [36] 王军, 朱杰, 罗茜. 中国数字经济发展水平及演变测度[J]. *数量经济技术经济研究*, 2021, 38(7): 26-42.

(责任编辑: 张悦)

Impact of Generative Artificial Intelligence on the Total Factor Productivity of Manufacturing Enterprises

Qiao Penghua, Zhao Bangbang, Han Xianfeng

(Faculty of Management and Economics, Kunming University of Technology, Kunming 650500, China)

Abstract: The application of generative artificial intelligence (GenAI) has become a critical pathway for reshaping enterprise production management structures and enhancing competitiveness. Existing literature highlights its dual role in reducing R&D costs, automating workflows, and facilitating human-machine collaboration. While intelligent technologies are generally expected to drive productivity growth, there is a lack of systematic explanation of how generative artificial intelligence affects enterprise total factor productivity (TFP), with most mechanism analyses remaining at the level of technology-enablement hypotheses. The transmission path of "technology application → factor reorganization → efficiency leap" has yet to be empirically tested, and the "black box" between technological advantage and productivity improvement remains unexplored.

Therefore, this study selects Chinese A-share manufacturing companies from 2017 to 2022 as samples and conducts an in-depth investigation into the mechanism of generative artificial intelligence in this critical sector. The study employs BERT intelligent text analysis to construct measurement indicators for GenAI adoption and systematically examines its impact on total factor productivity and underlying mechanisms. Baseline regression reveals that GenAI application significantly improves TFP. The promotion effect essentially reflects comprehensive outcomes of expanded enterprise resource bases, improved key resource allocation, and enhanced resource value release capabilities. Mechanism analysis identifies three critical channels: at the strategic resource level, GenAI optimizes R&D configuration; at the operational resource level, it improves internal management efficiency; and at the production factor resource level, it enhances data element utilization. These three layers collectively drive TFP improvement.

Moderation analysis demonstrates that the relationship between GenAI and TFP is contingent on contextual conditions. Specifically, human capital upgrading within enterprise organizations and digital infrastructure improvement outside organizations exert positive moderating effects, amplifying AI's productivity benefits. Heterogeneity analysis reveals significant differences across enterprise characteristics and regional contexts. Regarding enterprise heterogeneity, while firms with different property rights all achieve productivity improvements when applying GenAI, the efficacy strongly depends on contextual features. The effects are more pronounced in non-labor-intensive, non-asset-intensive, and technology-intensive enterprises, whereas relatively limited in asset-intensive and labor-intensive firms. This indicates that GenAI functions as a knowledge-enabling technology that synergizes with flexible production structures and innovation activities, complementing high-skilled human capital and high-intensity innovation activities rather than simply replacing procedural labor. Regarding regional heterogeneity, significant effects in eastern and central regions confirm the supporting role of mature economic ecosystems, while the insignificant effect in the western region warns of potential "lag effects" in technology diffusion. Furthermore, when regions with high innovation capabilities apply GenAI, the impact on manufacturing TFP becomes more significant. Notably, regions with low levels of digital economic development exhibit a "filling effect", providing optimistic practical possibilities and theoretical inspirations for latecomers to achieve "technological leapfrogging" through strategic AI adoption.

These findings provide empirical support for understanding how "artificial intelligence +" promotes manufacturing productivity. They verify that GenAI enhances TFP while revealing the internal mechanisms and practical boundaries of its effects. Specifically, GenAI is not a universally applicable and automatically effective "universal technology", but rather a strategic resource that can fully release its efficacy only under appropriate resource bases and environmental conditions. The productivity gains depend on whether AI can form effective coupling with enterprises' internal knowledge resources, organizational resources, and data resources. This conclusion offers explanatory evidence and theoretical inspiration for understanding how GenAI enables the real economy, promotes transformation and upgrading of manufacturing industries, and cultivates new quality productive forces.

Key Words: Large Models; Generative Artificial Intelligence; Total Factor Productivity; Digital Intelligence Technology; Technological Innovation